CREDIT RISK · MACHINE LEARNING · PROJETO INDEPENDENTE

Quem Vai Dar Default?

Logistic Regression versus Random Forests em Credit Risk, com Teste Out-of-Time em Empréstimos da LendingClub, 2007–2013

Lucas de Morais Ruga

Insper Instituto de Ensino e Pesquisa, São Paulo, Brasil
Projeto independente de portfólio, a partir de um case do AI for Business & Finance Certificate (Columbia Business School Executive Education × Wall Street Prep)

STATUS Modelo e plano de análise definidos antes de rodar o teste; resultados a serem adicionados.

DADOS	MODELOS	DESENHO	FOCO
Empréstimos LendingClub emitidos em 2007–2013	**Logistic regression vs. random forest**	**Aleatório 70/30 em 2007–2012 + holdout 2013**	**Ordenar risco de default out-of-time**

01 PROBLEMA

Um credor precisa decidir, para cada pedido de empréstimo, qual a chance de o tomador parar de pagar. Um modelo que ordena os candidatos pela probabilidade de default permite aprovar os mais seguros e precificar ou recusar os mais arriscados. A pergunta por trás deste projeto é quão bem um modelo construído apenas com as informações do pedido de empréstimo separa os empréstimos que vão dar default dos que serão pagos.

O projeto parte do case “Predicting creditworthiness” do AI for Business & Finance Certificate. O case prevê default em empréstimos ao consumidor da LendingClub a partir de 13 variáveis do tomador e do empréstimo. Ele estima uma logistic regression e uma random forest, escolhe a profundidade das árvores testando profundidades de 1 a 20 e interpreta a melhor forest com permutation importance e partial dependence plots. Duas características do case limitam o que ele consegue mostrar: a profundidade é escolhida no mesmo test set que reporta a performance final, e a divisão train/test é aleatória, de modo que empréstimos de todos os anos aparecem dos dois lados.

Este projeto reimplementa o case com dados baixados de forma independente, mantém o modelo inalterado e acrescenta um teste out-of-time em empréstimos emitidos depois do período de desenvolvimento. Perguntamos, portanto:

> **PERGUNTA DE PESQUISA**
>
> **Uma random forest ordena os tomadores por risco de default melhor do que uma logistic regression em empréstimos emitidos depois do período de desenvolvimento, e como os dois se comparam com o próprio rating de risco do credor e com o acaso?**

02 DESCRIÇÃO DO MODELO E MÉTODOS

VISÃO GERAL

O modelo é um classificador binário. Cada empréstimo é descrito por 13 variáveis conhecidas no momento da emissão, e o modelo devolve uma probabilidade prevista de default. Dois classificadores são comparados: uma logistic regression e uma random forest de 100 árvores cuja profundidade é escolhida entre 1 e 20 (Figura 1). Os dois são estimados em empréstimos emitidos em 2007–2012 e depois avaliados em empréstimos emitidos em 2013, que nunca são usados para estimar nem para escolher a profundidade.

FIGURA 1 · PIPELINE DO PROJETO



As etapas 1–5 reproduzem o case original no período de desenvolvimento; a etapa 6 é aplicada uma única vez, com todas as escolhas fixadas.

ESPECIFICAÇÃO DO MODELO

Dados. Os dados são os registros públicos, empréstimo a empréstimo, dos empréstimos aceitos pela LendingClub emitidos de 2007 ao quarto trimestre de 2018, baixados de um espelho público no Kaggle; o arquivo de dados do curso não é usado. A amostra mantém os empréstimos emitidos de 2007 a 2013. Os empréstimos têm prazo de 36 ou 60 meses, então um empréstimo de 60 meses emitido em dezembro de 2013 vence em dezembro de 2018, o fim dos dados. Todo empréstimo da amostra teve, portanto, tempo de chegar ao status final. Empréstimos com status ainda em aberto (current, late ou in grace period) são excluídos, assim como linhas com valores faltantes em qualquer uma das 13 variáveis.

Variável resposta. O resultado do empréstimo i é

VARIÁVEL RESPOSTA

$$y_i = \begin{cases} 1 & \text{se o empréstimo foi charged off ou está em default,} \\ 0 & \text{se o empréstimo foi fully paid.} \end{cases}$$

Variáveis. Os 13 preditores são os do case original: valor do empréstimo, prazo (36 ou 60 meses), tempo de emprego (0 a 10 anos), situação de moradia, renda anual, status de verificação da renda, debt-to-income ratio (dti), inadimplências nos últimos dois anos, linhas de crédito abertas, public records, revolving balance, revolving utilization e anos de histórico de crédito. O case usa situação de moradia e status de verificação como colunas numéricas únicas, então cada uma é codificada como indicador binário: moradia vale 1 se o tomador tem casa própria ou financiada, e verificação vale 1 se a renda foi verified ou source verified. Os anos de histórico de crédito são calculados a partir da data de emissão e da data da primeira linha de crédito do tomador:

HISTÓRICO DE CRÉDITO

$$\text{years_of_credit}_i = \frac{\text{issue_date}_i - \text{earliest_cr_line}_i}{365.25}$$

Escrevemos $\mathbf{x}_i$ para o vetor dos 13 preditores.

Modelos de previsão. A logistic regression modela a probabilidade de default com as 13 variáveis entrando de forma linear. A random forest faz a média das probabilidades de default previstas por $B = 100$ classification trees, cada uma com profundidade máxima d. Como no case, são estimadas forests para cada profundidade $d \in \{1, \ldots, 20\}$ e fica a profundidade com maior AUC no test set.

LOGISTIC REGRESSION (LR)	$\hat{p}_i = \Pr(y_i = 1 \mid \mathbf{x}_i) = \dfrac{1}{1 + e^{-(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x}_i)}}$
RANDOM FOREST (RF_D)	$\hat{p}_i = \dfrac{1}{B} \sum_{b=1}^{B} \hat{p}_b(\mathbf{x}_i)$
ESCOLHA DA PROFUNDIDADE	$d^* = \arg\max_d \ \mathrm{AUC}_{\mathrm{test}}(\mathrm{RF}_d)$

REGRA DE DECISÃO E DESENHO TRAIN/TEST

Regra de decisão. O case para na previsão de default e não tem regra de decisão. Para a avaliação, cada modelo vira uma regra de aprovação: um empréstimo é aprovado se a probabilidade prevista de default for menor ou igual a um cutoff τ. O cutoff é definido para atingir uma taxa de aprovação $a(\tau)$, de 10% a 100% dos pedidos, e a regra é julgada pela taxa de default entre os empréstimos aprovados.

REGRA DE APROVAÇÃO	$\mathrm{aprova}_i = \mathbf{1}\{\hat{p}_i \le \tau\}$

Desenho train/test. A amostra é dividida em duas partes (Figura 2). Os empréstimos emitidos em 2007–2012 formam o conjunto de desenvolvimento. Dentro dele, o case original é reproduzido exatamente: divisão train/test aleatória 70/30 com seed 123, a logistic regression e as 20 forests estimadas na parte de train, e d^* escolhido na parte de test. Os empréstimos emitidos em 2013 formam o holdout. Eles são usados uma única vez, depois que os dois modelos e d^* estão fixados, e os modelos não são reestimados com eles. Como o notebook original é distribuído sem resultados e seu arquivo de dados não é usado, a reprodução é verificada rodando o código do case sem alterações no conjunto de desenvolvimento e obtendo todos os seus outputs.

FIGURA 2 · DESENHO TRAIN/TEST



O case é reproduzido em empréstimos emitidos em 2007–2012 com divisão aleatória 70/30; os empréstimos emitidos em 2013 formam um holdout out-of-time intocado. Train/test aparecem como proporções, não como anos.

MEDIDAS DE PERFORMANCE

Os modelos são comparados por quão bem colocam os empréstimos que deram default acima dos que foram pagos. O AUC é a probabilidade de um empréstimo com default, escolhido ao acaso, receber probabilidade prevista maior do que um empréstimo pago, escolhido ao acaso. O coeficiente de Gini reescala o AUC de modo que 0 é o acaso e 1 é a ordenação perfeita. A estatística de Kolmogorov–Smirnov (KS) é a maior distância entre as distribuições acumuladas das probabilidades previstas para empréstimos com default (F_1) e pagos (F_0). A permutation importance da variável k é a queda em um score S quando essa variável é embaralhada ao acaso, na média de $R = 5$ embaralhamentos. O case usa o score default do classificador, a accuracy; a avaliação também a reporta com o AUC como score.

AUC	$\mathrm{AUC} = \Pr\left(\hat{p}_i > \hat{p}_j \mid y_i = 1,\ y_j = 0\right)$	**GINI**	$\mathrm{Gini} = 2\,\mathrm{AUC} - 1$
KOLMOGOROV–SMIRNOV	$\mathrm{KS} = \max_t \left\lvert F_1(t) - F_0(t) \right\rvert$	**PERMUTATION IMPORTANCE**	$I_k = S(\mathbf{X}) - \frac{1}{R}\sum_{r=1}^{R} S\left(\mathbf{X}^{(k,r)}\right)$

MEDIDAS

(1) Reprodução
No conjunto de desenvolvimento: AUC de test da logistic regression e da forest de profundidade 1, a curva de AUC por profundidade, d^*, permutation importance e partial dependence plots, como no case.

(2) Performance no holdout
AUC, Gini e KS da logistic regression e de RF_{d^*} no holdout de 2013, com intervalos de confiança de 95% por bootstrap com 1.000 reamostragens, inclusive para a diferença de AUC entre os dois modelos.

(3) Benchmarks
Comparação com o sub-grade da própria LendingClub (A1 a G5) usado como score de risco, e com um score aleatório.

(4) Otimismo da escolha
AUC de RF_{d^*} no test set do desenvolvimento, onde d^* foi escolhido, contra seu AUC no holdout.

(5) Calibration
Probabilidade prevista média contra taxa de default observada em cada decil de probabilidade prevista no holdout.

(6) Curva de aprovação
Taxa de default entre os empréstimos aprovados para taxas de aprovação de 10% a 100%, para os dois modelos e para o sub-grade.

(7) Estabilidade da interpretação
Permutation importance no test set do desenvolvimento e no holdout, com accuracy e com AUC como score.

03 JUSTIFICATIVA DAS ESCOLHAS

O modelo é mantido idêntico ao do case original de propósito. O objetivo é testar se o resultado do case se sustenta em empréstimos novos, não construir um modelo de crédito melhor. Acrescentar variáveis, ajustar mais a forest ou mudar a grade de profundidades depois de olhar o holdout faria os resultados do holdout deixarem de ser out-of-sample. Todas as extensões ficam, portanto, na avaliação, e não no modelo.

A amostra termina nos empréstimos emitidos em 2013 para que todo empréstimo tenha tido tempo de chegar ao status final. Incluir empréstimos posteriores manteria apenas os que já deram default ou foram quitados antes do prazo, e a taxa de default dos anos recentes ficaria distorcida.

O case escolhe a profundidade das árvores nos mesmos dados que reportam sua performance, então essa performance é otimista. Manter essa etapa sem alteração e acrescentar um holdout que não participou de nenhuma escolha mede o tamanho desse otimismo diretamente, pela medida (4). O holdout é posterior no tempo aos dados de desenvolvimento, que é como um modelo de crédito é usado na prática: construído com empréstimos passados e aplicado a pedidos novos.

O AUC sozinho não mostra se um modelo agrega valor. O sub-grade da LendingClub resume a avaliação de risco do próprio credor no momento do empréstimo, então um modelo que não ordena melhor do que o sub-grade acrescenta pouco ao que o credor já sabia; um score aleatório define o piso. O AUC mede ordenação, não se uma probabilidade prevista de 10% corresponde a uma taxa de default de 10%, o que importa quando as probabilidades são usadas para precificar; a calibration verifica isso. A curva de aprovação traduz a ordenação na decisão que o credor de fato toma. A accuracy é um score fraco quando a maioria dos empréstimos é paga, então a permutation importance também é reportada com o AUC.

04 PLANO DE ANÁLISE

A análise segue três etapas.

1

Reproduzir

A reimplementação é verificada rodando o código do case sem alterações no conjunto de desenvolvimento de 2007–2012 e obtendo a medida (1).

2

Fixar e aplicar

A logistic regression, RF_{d^*} e todas as escolhas da Tabela 1 são fixadas, e os modelos são aplicados uma única vez ao holdout de 2013.

3

Avaliar

As medidas (2)–(7) são calculadas e apresentadas em um gráfico de AUC por profundidade, curvas ROC dos dois modelos e do sub-grade no holdout, uma tabela de performance com intervalos de confiança, um gráfico de AUC no desenvolvimento versus no holdout, um gráfico de calibration, um gráfico da curva de aprovação, gráficos de permutation importance e partial dependence plots.

TABELA 1 · PARÂMETROS, VALORES E JUSTIFICATIVA

PARÂMETRO	SÍMBOLO	VALOR	JUSTIFICATIVA
Fonte dos dados	–	Empréstimos aceitos LendingClub	Dados públicos empréstimo a empréstimo; arquivo do curso não usado
Período de emissão	–	2007–2013	Último ano em que empréstimos de 60 meses vencem até o fim dos dados (dez/2018)
Variável resposta	y_i	Charged off ou default vs. fully paid	Empréstimos em aberto excluídos
Preditores	$\mathbf{x}_i$	13 variáveis	Case original
Moradia, verificação	–	Indicadores binários	O case usa cada uma como uma coluna numérica
Valores faltantes	–	Linhas removidas	Mantém o código simples
Conjunto de desenvolvimento	–	Empréstimos emitidos 2007–2012	Reproduz o case
Divisão train/test	–	Aleatória 70/30, seed 123	Case original
Holdout	–	Empréstimos emitidos 2013	Out-of-time; usado uma vez, após todas as escolhas fixadas
Logistic regression	LR	13 termos lineares	Case original
Árvores por forest	B	100	Case original
Grade de profundidade	d	1–20	Case original
Escolha da profundidade	d^*	Maior AUC no test do desenvolvimento	Case original; otimismo medido em (4)
Repetições da permutação	R	5	Case original (default da biblioteca)
Benchmarks	–	Sub-grade da LendingClub; score aleatório	Avaliação do próprio credor; acaso
Reamostragens bootstrap	–	1.000	Intervalos de confiança de 95% para o AUC
Taxas de aprovação	$a(\tau)$	10%–100%	Traduz o ranking na decisão de crédito